

מבוא למערכות לומדות (67577) | תרגיל 1

שם: אלון בינר | ת"ז: 318418118
April 2, 2023

שאלה 2

אלגברה לינארית

(1) פיתרון:

תהא A מטריצה אורתוגונלית.
יהא $x \in V$.
אזי:

$$\begin{aligned} \|Ax\| &= \sqrt{\langle Ax, Ax \rangle} \stackrel{(1)}{=} \sqrt{(Ax) \cdot (Ax)} = \sqrt{(Ax)^t (Ax)} = \sqrt{(x^t A^t A x)} \stackrel{(2)}{=} \sqrt{(x^t I x)} = \\ &= \sqrt{(x^t x)} = \sqrt{\langle x, x \rangle} = \|x\| \end{aligned}$$

שוויון (1) נובע מכך שקבענו בקורס שמכפלה פנימית בה נשתמש היא המכפלה הסקלרית.
שוויון (2) נובע מאורתוגונליות A .

(2) פיתרון:

בהינתן מטריצה $A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix}$ נחשב את ה-SVD של A באופן הבא:
נמצא מטריצות U, Σ, V^T , כאשר U ו- V הן מטריצות אורתוגונליות ו- Σ מטריצה אלכסונית.
ראשית, נחשב:

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) = ((U \Sigma) V^T)^T (U \Sigma V^T) = (V (U \Sigma)^T) (U \Sigma V^T) = \\ &= (V \Sigma^T U^T) (U \Sigma V^T) = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T \end{aligned}$$

כשהשוויון האחרון נובע מאורתוגונליות U .
בנוסף:

$$A^T A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix}$$

כעת נמצא את הערכים העצמיים של A . לשם כך, נחשב את הפולינום האופייני של A , נשווה אותו לאפס ונקבל שהשורשים של הפולינום הם הערכים העצמיים של A :

$$\begin{aligned} \det(A^T A - \lambda I) &= \det \left(\begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix} - \begin{bmatrix} \lambda & 0 & 0 \\ 0 & \lambda & 0 \\ 0 & 0 & \lambda \end{bmatrix} \right) = \det \left(\begin{bmatrix} 2-\lambda & 0 & 2 \\ 0 & 2-\lambda & -2 \\ 2 & -2 & 4-\lambda \end{bmatrix} \right) = \\ &= -\lambda^3 + 8\lambda^2 - 12\lambda = -\lambda(\lambda^2 - 8\lambda + 12) = -\lambda(\lambda^2 - 2\lambda - 6\lambda + 12) = \end{aligned}$$

$$= -\lambda(\lambda(\lambda - 2) - 6(\lambda - 2)) = -\lambda(\lambda - 6)(\lambda - 2)$$

\Downarrow

$$\det(A - \lambda I) = 0 \iff -\lambda(\lambda - 6)(\lambda - 2) = 0$$

\Downarrow

$$\lambda \in \{0, 2, 6\}$$

כעת נחשב את הוקטורים העצמיים של A , לשם כך נמצא $v \neq 0$ המקיימים את המשוואה: $(AA^T - \lambda I)v = 0$ לכל $\lambda \in \{0, 2, 6\}$:

$$AA^T - \lambda I = \begin{bmatrix} 2-\lambda & 0 & 2 \\ 0 & 2-\lambda & -2 \\ 2 & -2 & 4-\lambda \end{bmatrix}$$

לכן, עבור $\lambda = 0$ מתקיים:

$$AA^T - \lambda I = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix}$$

$$v_1 = \begin{bmatrix} \frac{2}{\sqrt{2^2+0^2+2^2}} \\ \frac{0}{\sqrt{2^2+0^2+2^2}} \\ \frac{2}{\sqrt{2^2+0^2+2^2}} \end{bmatrix} = \begin{bmatrix} \frac{2}{\sqrt{4+0+4}} \\ 0 \\ \frac{2}{\sqrt{4+0+4}} \end{bmatrix} = \begin{bmatrix} \frac{2}{\sqrt{8}} \\ 0 \\ \frac{2}{\sqrt{8}} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ 0 \\ \frac{1}{\sqrt{2}} \end{bmatrix} \text{ ניקח ו"ע}$$

עבור $\lambda = 2$ מתקיים:

$$AA^T - \lambda I = \begin{bmatrix} 0 & 0 & 2 \\ 0 & 0 & -2 \\ 2 & -2 & 2 \end{bmatrix}$$

$$v_2 = \begin{bmatrix} 0 \\ 0 \\ \frac{2}{\sqrt{0^2+0^2+2^2}} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \frac{2}{\sqrt{0+0+4}} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \text{ ניקח ו"ע}$$

עבור $\lambda = 6$ מתקיים:

$$AA^T - \lambda I = \begin{bmatrix} -4 & 0 & 2 \\ 0 & -4 & -2 \\ 2 & -2 & -2 \end{bmatrix}$$

$$v_3 = \begin{bmatrix} \frac{-4}{\sqrt{(-4)^2+0^2+2^2}} \\ 0 \\ \frac{2}{\sqrt{(-4)^2+0^2+2^2}} \end{bmatrix} = \begin{bmatrix} \frac{-4}{\sqrt{20}} \\ 0 \\ \frac{2}{\sqrt{20}} \end{bmatrix} = \begin{bmatrix} \frac{-2}{\sqrt{5}} \\ 0 \\ \frac{1}{\sqrt{5}} \end{bmatrix} \text{ ניקח ו"ע}$$

מכך נסיק כי:

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{-2}{\sqrt{5}} \\ 0 & 0 & 0 \\ \frac{1}{\sqrt{2}} & 1 & \frac{1}{\sqrt{5}} \end{bmatrix}, \Sigma = \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{bmatrix}$$

כעת, נחשב את U .

נוכל לחשב את עמודות U לפי מה שראינו בתרגול:

$$t_1 = \frac{1}{\sqrt{6}} \cdot Av_3 = \begin{bmatrix} -\sqrt{\frac{2}{15}} \\ 0 \end{bmatrix} \Rightarrow u_1 = \frac{t_1}{\|t_1\|} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

$$t_2 = \frac{1}{\sqrt{2}} \cdot Av_2 = \begin{bmatrix} 0 \\ \sqrt{\frac{2}{3}} \end{bmatrix} \Rightarrow u_2 = \frac{t_2}{\|t_2\|} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

לכן:

$$U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

(3) פיתרון:

יהיו $v \in \mathbb{R}^n, u \in \mathbb{R}^m$. נגדיר $A = v \otimes u$.
על-פי הגדרה $A = vu^T$ ולכן $A \in \mathbb{R}^{n \times m}$.

אם נסמן $v = \begin{bmatrix} v_1 \\ \dots \\ v_n \end{bmatrix}, u = \begin{bmatrix} u_1 \\ \dots \\ u_m \end{bmatrix}$ אז מתקיים:

$$vu^T = \begin{bmatrix} v_1 \\ \dots \\ v_n \end{bmatrix} \begin{bmatrix} u_1 & \dots & u_m \end{bmatrix} = \begin{bmatrix} v_1 u_1 & v_1 u_2 & \dots & v_1 u_m \\ v_2 u_1 & v_2 u_2 & \dots & v_2 u_m \\ \dots & \dots & \dots & \dots \\ v_n u_1 & v_n u_2 & \dots & v_n u_m \end{bmatrix} = \begin{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ \dots \\ v_n \end{bmatrix} u_1 & \begin{bmatrix} v_1 \\ v_2 \\ \dots \\ v_n \end{bmatrix} u_2 & \dots & \begin{bmatrix} v_1 \\ v_2 \\ \dots \\ v_n \end{bmatrix} u_m \end{bmatrix}$$

לכל $t, k \in [m]$ שונים זה מזה מתקיים:

אם $u_t = 0$ אז העמודה ה- t של A שווה ל-0 ולכן תלויה לינארית בשאר העמודות של המטריצה.
אחרת, קיים סקלר $\frac{u_k}{u_t} \neq 0$ כך ש-

$$\begin{bmatrix} v_1 \\ \dots \\ v_n \end{bmatrix} u_t \cdot \frac{u_k}{u_t} = \begin{bmatrix} v_1 \\ \dots \\ v_n \end{bmatrix} u_k$$

לכן, כל וקטור בעמודה ה- t תלוי לינארית בוקטור העמודה ה- k .
לכן $\text{rank}(A) = \text{rank}(vu^T) = 1$.

(4) פיתרון:

יהא $(u_i)_{i=1}^n$ בסיס אורתונורמלי כלשהו ויהא $x \in \mathbb{R}^n$ שמתקבל כצירוף לינארי של איברי הבסיס.
יהא $k \in [1, n]$.

צריך להראות שהמקדם של u_k שווה ל- $\langle x, u_k \rangle$.
נסמן את המקדם של u_k ב- a_k .
אזי:

$$\langle x, u_k \rangle = \left\langle \sum_{j=1}^n a_j \cdot u_j, u_k \right\rangle = \sum_{j=1}^n \langle a_j \cdot u_j, u_k \rangle = \sum_{j=1}^n a_j \langle u_j, u_k \rangle \stackrel{(1)}{=} a_k$$

כאשר שוויון (1) נובע מאורתונורמליות הבסיס $(u_i)_{i=1}^n$.

אינפי בכמה משתנים

(5) פיתרון:

יהא $x \in \mathbb{R}^n$ קבוע ותהא $U \in \mathbb{R}^{n \times n}$ מטריצה אורתוגונלית קבועה.
צריך לחשב את היעקוביאן של $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ המוגדרת על-ידי

$$f(\sigma) = U \cdot \text{diag}(\sigma) U^T x$$

לכל $\sigma \in \mathbb{R}^n$

$$J(f(\sigma)) = \begin{bmatrix} \frac{\partial f_1(\sigma)}{\partial \sigma_1} & \dots & \frac{\partial f_1(\sigma)}{\partial \sigma_n} \\ \dots & \dots & \dots \\ \frac{\partial f_n(\sigma)}{\partial \sigma_1} & \dots & \frac{\partial f_n(\sigma)}{\partial \sigma_n} \end{bmatrix}$$

יהיו $i, j \in [n]$ אזי:

$$J(f(\sigma))_{i,j} = \frac{\partial f_i(\sigma)}{\partial \sigma_j} =$$

$$f_i(\sigma) = (U \cdot \text{diag}(\sigma) U^T x)_i =$$

$$\begin{aligned} U \text{diag}(\sigma) U^T x &= \begin{bmatrix} u_1^1 & \dots & u_n^1 \\ \dots & \dots & \dots \\ u_1^n & \dots & u_n^n \end{bmatrix} \begin{bmatrix} \sigma_1 & & \\ & \dots & \\ & & \sigma_n \end{bmatrix} \begin{bmatrix} u_1^T \\ \dots \\ u_n^T \end{bmatrix} x = \begin{bmatrix} u_1^1 \sigma_1 & u_2^1 \sigma_2 & \dots & u_n^1 \sigma_n \\ u_1^2 \sigma_1 & \dots & \dots & u_n^2 \sigma_n \\ \dots & \dots & \dots & \dots \\ u_1^n \sigma_1 & \dots & \dots & u_n^n \sigma_n \end{bmatrix} \begin{bmatrix} u_1^T \\ \dots \\ u_n^T \end{bmatrix} x = \\ &= \begin{bmatrix} u_1 \sigma_1 & \dots & u_n \sigma_n \end{bmatrix} \begin{bmatrix} u_1^T \\ \dots \\ u_n^T \end{bmatrix} x = \left(\sum_{i=1}^n u_i \sigma_i u_i^T \right) x = \left(\sum_{i=1}^n \sigma_i u_i u_i^T \right) x = \left(\sum_{i=1}^n \sigma_i (u_i u_i^T) \right) x = \\ &= (\sigma_1 (u_1 u_1^T) + \sigma_2 (u_2 u_2^T) + \dots + \sigma_n (u_n u_n^T)) x = \\ &= (\sigma_1 (u_1 u_1^T)) x + (\sigma_2 (u_2 u_2^T)) x + \dots + (\sigma_n (u_n u_n^T)) x = \\ &= \sum_{i=1}^n (\sigma_i (u_i u_i^T) x) \end{aligned}$$

\Downarrow

$$\begin{aligned} \forall k \in [n] \quad f_k(\sigma) &= \left(\sum_{i=1}^n (\sigma_i (u_i u_i^T) x) \right)_k = \left(\sum_{i=1}^n (\sigma_i (u_i u_i^T) x)_k \right) = \\ &= \left(\sum_{i=1}^n \sigma_i (u_i u_i^T x)_k \right) \end{aligned}$$

לכן לכל $k, l \in [n]$ מתקיים:

$$J(f(\sigma))_{k,l} = \frac{\partial f_k(\sigma)}{\partial \sigma_l} = (u_l u_l^T x)_k$$

כלומר,

$$J(f(\sigma)) = \begin{bmatrix} (u_1 u_1^T x)_1 & \dots & (u_n u_n^T x)_1 \\ \dots & \dots & \dots \\ (u_1 u_1^T x)_n & \dots & (u_n u_n^T x)_n \end{bmatrix} = \begin{bmatrix} u_1 u_1^T x & \dots & u_n u_n^T x \end{bmatrix}$$

(6) פיתרון:

$$\nabla (h(\sigma)) = \nabla \left(\frac{1}{2} \|f(\sigma) - y\|^2 \right)$$

$$h(\sigma) = \frac{1}{2} \|f(\sigma) - y\|^2 = \frac{1}{2} \left\| \begin{bmatrix} (f(\sigma) - y)_1 \\ \dots \\ (f(\sigma) - y)_n \end{bmatrix} \right\|^2 = \frac{1}{2} \sum_{i=1}^n (f(\sigma) - y)_i^2 =$$

מתקיים כי:

$$\begin{aligned} \|f(\sigma) - y\|^2 &= \langle f(\sigma) - y, f(\sigma) - y \rangle = \langle f(\sigma) - y, f(\sigma) \rangle - \langle f(\sigma) - y, y \rangle = \\ &= \langle f(\sigma), f(\sigma) \rangle - \langle y, f(\sigma) \rangle - (\langle f(\sigma), y \rangle - \langle y, y \rangle) = \\ &= \langle f(\sigma), f(\sigma) \rangle - \langle y, f(\sigma) \rangle - \langle f(\sigma), y \rangle + \langle y, y \rangle = \\ &= \|f(\sigma)\|^2 - \langle y, f(\sigma) \rangle - \langle y, f(\sigma) \rangle + \|y\|^2 = \\ &= \|f(\sigma)\|^2 - 2\langle y, f(\sigma) \rangle + \|y\|^2 \end{aligned}$$

נגדיר פונקציה:

$$g(\sigma) = \frac{1}{2} (\|\sigma\|^2 - 2\langle y, \sigma \rangle + \|y\|^2)$$

לכן:

$$\|f(\sigma)\|^2 - 2\langle y, f(\sigma) \rangle + \|y\|^2 = (g(f(\sigma))) = (g \circ f)(\sigma) = h(\sigma)$$

אזי לפי משפט שראינו בתרגול מתקיים כי:

$$J_x(h) = J_x(g \circ f) = J_{f(x)}(g) J_x(f)$$

מתקיים ש:

$$\begin{aligned} J_x(g) &= \frac{\partial}{\partial x} \left(\frac{1}{2} (\|x\|^2 - 2\langle y, x \rangle + \|y\|^2) \right) = \frac{\partial}{\partial x} \left(\frac{1}{2} (\langle x, x \rangle - 2\langle y, x \rangle + \langle y, y \rangle) \right) = \\ &= \frac{\partial}{\partial x} \left(\frac{1}{2} (x^T x - 2y^T x + y^T y) \right) = \frac{1}{2} (2x^T - 2y^T) = (x^T - y^T) = (x - y)^T \end{aligned}$$

ולכן:

$$J_{f(\sigma)}(g) = (f(\sigma) - y)^T$$

לכן

$$J_\sigma(h) = (f(\sigma) - y)^T J_\sigma(f)$$

(7) פיתרון:

עבור פונקציית ה-Softmax, אותה נסמן ב- S , המוגדרת על-ידי:

$$\forall j \in [k] \quad S(x)_j = \frac{e^{x_j}}{\sum_{k=1}^d e^{x_k}}$$

לכל $i \in [k], j \in [d]$ מתקיים כי:

$$(J_x(S))_{i,j} = \frac{\partial S_i(x)}{\partial x_j}$$

אם $i = j$ אז לפי מה שראינו בתרגול:

$$\frac{\partial S_i(x)}{\partial x_i} = S(x)_i (1 - S(x)_i)$$

אחרת, $i \neq j$. נסמן ב- f_i וב- g את הפונקציות $f_i(x) = e^{x_i}$ ו- $g(x) = \sum_{k=1}^d e^{x_k}$ בהתאמה. אזי $\frac{\partial f_i(x)}{\partial x_j} = 0$, $\frac{\partial g(x)}{\partial x_j} = e^{x_j}$ ולכן

$$\begin{aligned} \frac{\partial S_i(x)}{\partial x_j} &= \frac{\partial \frac{f_i}{g}(x)}{\partial x_j} = \frac{\partial \frac{f_i(x)}{g(x)}}{\partial x_j} = \frac{\frac{\partial f_i(x)}{\partial x_j} \cdot g(x) - f_i(x) \cdot \frac{\partial g(x)}{\partial x_j}}{(g(x))^2} = \\ &= \frac{0 \cdot g(x) - e^{x_i} \cdot e^{x_j}}{\left(\sum_{k=1}^d e^{x_k}\right)^2} = \frac{-e^{x_i}}{\sum_{k=1}^d e^{x_k}} \cdot \frac{e^{x_j}}{\sum_{k=1}^d e^{x_k}} = -(S(x))_i \cdot (S(x))_j \end{aligned}$$

לכן:

$$J_x(S) = \begin{bmatrix} S(x)_1 \cdot (1 - S(x)_1) & -S(x)_1 \cdot S(x)_2 & \dots & -S(x)_1 \cdot S(x)_n \\ \dots & \dots & \dots & \dots \\ -S(x)_n \cdot S(x)_1 & \dots & -S(x)_n \cdot S(x)_{n-1} & S(x)_n \cdot (1 - S(x)_n) \end{bmatrix}$$

(8) פיתרון:

תהא $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ המוגדרת על-ידי $f(x, y) = x^3 - 5xy - y^5$. אזי:

$$\frac{\partial f}{\partial x \partial x} = \frac{\partial}{\partial x} (3x^2 - 5y) = 6x$$

$$\frac{\partial f}{\partial x \partial y} = \frac{\partial}{\partial x} (-5x - 5y^4) = -5$$

$$\frac{\partial f}{\partial y \partial x} = \frac{\partial}{\partial y} (3x^2 - 5y) = -5$$

$$\frac{\partial f}{\partial y \partial y} = \frac{\partial}{\partial y} (-5x - 5y^4) = -20y^3$$

נסיק אפוא ש:

$$H_{(x,y)} f = \begin{bmatrix} 6x & -5 \\ -5 & -20y^3 \end{bmatrix}$$

קמירות

(9) פיתרון:

צריך להראות ש- $C := \bigcap_{i \in I} C_i$ היא קבוצה קמורה כאשר $\{C_i : i \in I\}$ הוא אוסף קבוצות קמורות. נוכיח את הטענה באינדוקציה על $|I|$.

בסיס:

עבור $|I| = 0$, מתקיים ש- $I = \emptyset$ לכן $\bigcap_{i \in I} C_i = \emptyset$. אזי $C = \emptyset$ וההגדרה לקבוצה קמורה מתקיימת עבורה באופן ריק. עבור $|I| = 1$, מתקיים ש- $\bigcap_{i \in I} C_i = C_1$ לכן $C = C_1$. היות ש- $C_1 \in \{C_i : i \in I\}$ אז היא קבוצה קמורה לכן C היא קבוצה קמורה.

צעד: נניח שהטענה מתקיימת עבור אוסף קבוצות קמורות בגודל $|I| - 1$.

כלומר עבור $C' := \bigcap_{i \in I'} C_i$ כאשר $\{C_i : i \in I'\}$ הוא אוסף קבוצות קמורות בגודל $|I| - 1$.

נוכיח ש- $C = \bigcap_{i \in I} C_i$ היא גם קבוצה קמורה, כאשר $I = I' \cup \{i_{|I|}\}$. הוכחה זו מספיקה עבור קבוצה I מסוג זה משום שמהנחת האינדוקציה נובע שלכל קבוצה I קיימת קבוצה קמורה $I' = I \setminus \{i_{|I|}\}$ עבורה $C' \setminus C_{i_{|I|}}$ היא קבוצה קמורה.

נסמן $I' = \{i_1, i_2, \dots, i_{|I|-1}\}$.

נשים לב כי נוכל לכתוב את C בתור $C' \cap C_{i_{|I|}}$. מהנחת האינדוקציה נובע ש- C' היא קבוצה קמורה. בנוסף, נתון לנו ש- $C_{i_{|I|}}$ היא קבוצה קמורה. נפעיל שוב את הנחת האינדוקציה ונסיק מכך ש- $C' \cap C_{i_{|I|}}$ היא גם קבוצה קמורה.

(10) פיתרון:

צריך להראות שסכום הוקטורי $C_1 + C_2 := \{c_1 + c_2 : c_1 \in C_1, c_2 \in C_2\}$ כאשר C_1 ו- C_2 הן קבוצות קמורות, הוא גם קבוצה קמורה. יהיו $u, v \in C_1 + C_2$. אזי קיימים u_1, u_2 עבורם $u = u_1 + u_2$ וגם $u_1 \in C_1, u_2 \in C_2$. בנוסף, ישנם v_1, v_2 עבורם $v = v_1 + v_2$ וגם $v_1 \in C_1, v_2 \in C_2$.

יהא $\alpha \in [0, 1]$.

צריך להראות ש- $(1 - \alpha)u + \alpha v \in C_1 + C_2$.

מתקיים כי:

$$(1 - \alpha)u + \alpha v = (1 - \alpha)(u_1 + u_2) + \alpha(v_1 + v_2) =$$

$$= (1 - \alpha)u_1 + (1 - \alpha)u_2 + \alpha v_1 + \alpha v_2 =$$

$$= (1 - \alpha)u_1 + \alpha v_1 + (1 - \alpha)u_2 + \alpha v_2$$

היות ש- C_1 קבוצה קמורה ו- $u_1, v_1 \in C_1$ אזי $(1 - \alpha)u_1 + \alpha v_1 \in C_1$.

היות ש- C_2 קבוצה קמורה ו- $u_2, v_2 \in C_2$ אזי $(1 - \alpha)u_2 + \alpha v_2 \in C_2$.

יהיו C_1, C_2 קבוצות קמורות ויהיו $u_1, v_1 \in C_1$ ו- $u_2, v_2 \in C_2$.

אזי לכל $\alpha \in [0, 1]$ מתקיים ש- $(1 - \alpha)u_1 + \alpha v_1 \in C_1$ וגם $(1 - \alpha)u_2 + \alpha v_2 \in C_2$.

לכן $(1 - \alpha)u + \alpha v \in C_1 + C_2$ לכן $C_1 + C_2$ היא קבוצה קמורה.

(11) פיתרון:

צריך להראות שלכל סקלר λ ולכל קבוצה קמורה C , מתקיים ש- $\lambda C := \{\lambda c : c \in C\}$.

יהא λ סקלר ותהא C קבוצה קמורה.

יהיו $u, v \in \lambda C$ ויהא $\alpha \in [0, 1]$.

אזי $(1 - \alpha)u + \alpha v \in C$.

נחשב:

$$((1 - \alpha)u + \alpha v) = \left((1 - \alpha)\lambda \frac{u}{\lambda} + \alpha \lambda \frac{v}{\lambda} \right) = \lambda \left((1 - \alpha) \frac{u}{\lambda} + \alpha \frac{v}{\lambda} \right)$$

היות ש- λC ו- $u, v \in \lambda C$ אזי $\frac{u}{\lambda}, \frac{v}{\lambda} \in C$ לכן $(1 - \alpha) \frac{u}{\lambda} + \alpha \frac{v}{\lambda} \in C$.

לכן $\lambda \left((1 - \alpha) \frac{u}{\lambda} + \alpha \frac{v}{\lambda} \right) \in \lambda C$.

תאוריית ההערכה

(12) פיתרון:

יהיו $\{x_i\}_{i=1}^{\mathbb{N}}$ דגימות של משתנים מקריים שווי התפלגות בלתי-תלויים שמתפלגים מעל פונקציית התפלגות \mathcal{P} . \mathcal{P} היא פונקציית התפלגות בעלת תוחלת סופית ושונות סופית.

יהא $n \in \mathbb{N}$ קבוע.

צריך להראות שמשערך ממוצע הדגימות, $\hat{\mu}_n$, המוגדר על-ידי $\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n x_i$, הוא קונסיסטנטי. יהא $\varepsilon > 0$.

צריך להראות ש- $\lim_{n \rightarrow \infty} (\mathcal{P}(|\hat{\mu}_n - \mu| > \varepsilon)) = 0$. מתקיים כי:

$$\mathcal{P}(|\hat{\mu}_n - \mu| > \varepsilon) \stackrel{(1)}{\leq} \frac{\text{Var}(\hat{\mu}_n)}{\varepsilon^2} \stackrel{(2)}{=} \frac{\frac{\sigma^2}{n}}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2 n}$$

כאי-שוויון (1) הוא אי-שוויון צ'בישב ושוויון (2) נובע מהחישוב של משערך ממוצע הדגימות עבור n דגימות, $\hat{\mu}_n$, שאליו הגענו בהרצאה.

לכן:

$$\lim_{n \rightarrow \infty} (\mathcal{P}(|\hat{\mu}_n - \mu| > \varepsilon)) = \lim_{n \rightarrow \infty} \left(\frac{\sigma^2}{\varepsilon^2 n} \right) = 0$$

כשהשוויון האחרון נובע מאריתמטיקה של גבולות.

(13) פיתרון:

יהיו x_1, \dots, x_m תצפיות שנדגמות באופן בלתי תלוי עם התפלגות גאוסיאנית רבת משתנים עם תוחלת של $\mu \in \mathbb{R}^d$ ומטריצת שונות $\Sigma \in \mathbb{R}^{d \times d}$. נספק ביטוי עבור פונקציית ה- $\log - \text{likelihood}$ של $\mathcal{N}(\mu, \Sigma)$.

מתקיים כי:

$$\begin{aligned} \mathcal{L}(\mu, \Sigma | x_1, \dots, x_m) &= f_{\mu, \Sigma}(x_1, \dots, x_m) = \prod_{i=1}^m f_{\mu, \Sigma}(x_i) = \\ &= \prod_{i=1}^m \left(\frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \exp \left(-\frac{1}{2} \cdot (x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \right) \right) = \\ &= \left(\frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \right)^m \exp \left(\sum_{i=1}^m \left(-\frac{1}{2} \cdot (x_i - \mu)^T \Sigma^{-1} \cdot (x_i - \mu) \right) \right) = \\ &= \left((2\pi)^d |\Sigma| \right)^{-\frac{m}{2}} \exp \left(-\frac{1}{2} \sum_{i=1}^m \left((x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \right) \right) \end{aligned}$$

אזי:

$$\begin{aligned} \log(\mathcal{L}(\mu, \Sigma | x_1, \dots, x_m)) &= \log \left(\left((2\pi)^d |\Sigma| \right)^{-\frac{m}{2}} \exp \left(-\frac{1}{2} \sum_{i=1}^m \left((x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \right) \right) \right) = \\ &= \log \left(\left((2\pi)^d |\Sigma| \right)^{-\frac{m}{2}} \right) + \log \left(\exp \left(-\frac{1}{2} \sum_{i=1}^m \left((x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \right) \right) \right) = \\ &= -\frac{m}{2} \left(\log \left((2\pi)^d |\Sigma| \right) \right) - \frac{1}{2} \sum_{i=1}^m \left((x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \right) = \end{aligned}$$

$$\begin{aligned}
&= -\frac{m}{2} \left(\log \left((2\pi)^d \right) + \log (|\Sigma|) \right) - \frac{1}{2} \sum_{i=1}^m \left((x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \right) = \\
&= -\frac{m}{2} \log \left((2\pi)^d \right) - \frac{m}{2} \log (|\Sigma|) - \frac{1}{2} \sum_{i=1}^m \left((x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \right) = \\
&= -\frac{md}{2} \log (2\pi) - \frac{m}{2} \log (|\Sigma|) - \frac{1}{2} \sum_{i=1}^m \left((x_i - \mu)^T \Sigma^{-1} (x_i - \mu) \right)
\end{aligned}$$

חלק פרקטי:


שאלה 1:

פיתרון:

```
(9.954743292509804, 0.9752096659781323)
```


שאלה 2: גרף:

Distance between estimated expectation and the true expectation



שאלה 3: גרף:

Empirical PDF of fitted model in question 1




היינו מצפים לראות גרף פעמון שבו פונקציית ה pdf מקבלת ערכים גבוהים יותר ככל שמספר הדגימות קרוב יותר לתוחלת (שהיא 10)

שאלה 4: פיתרון:

```
[ -0.02282878 -0.04313959 3.9932571 -0.02038981]
[[ 0.91578223 0.16622123 -0.03423861 0.46244021]
 [ 0.16620092 1.97225175 -0.00986527 0.04555112]
 [-0.03022252 -0.00582887 0.97462985 -0.0203261 ]
 [ 0.46244265 0.04557387 -0.02433975 0.97158515]]
```

שאלה 5: גרף:

Log-likelihood of expectation dependi



שאלה 6: פיתרון:

```
Maximum Likelihood: [-0.05  3.97]
```